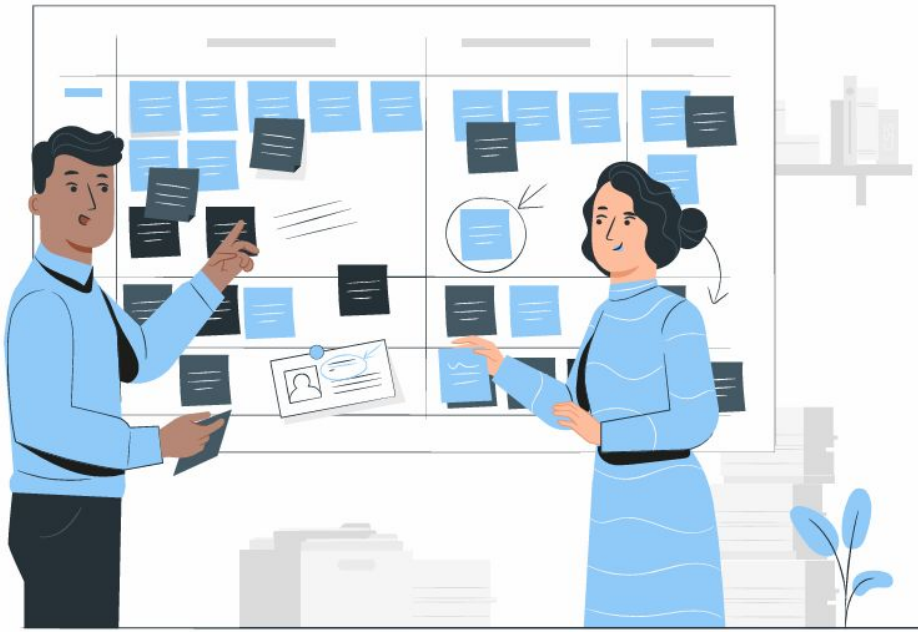
Домашнее задание

Построение архитектуры хранилища данных





Описание:

Необходимо разработать и реализовать data warehouse для вымышленной компании, которая занимается продажей электроники. Data warehouse должен содержать данные о продажах, клиентах, продуктах, складах.



01

Сформулировать бизнес-требования и цели создания data warehouse

Цели:

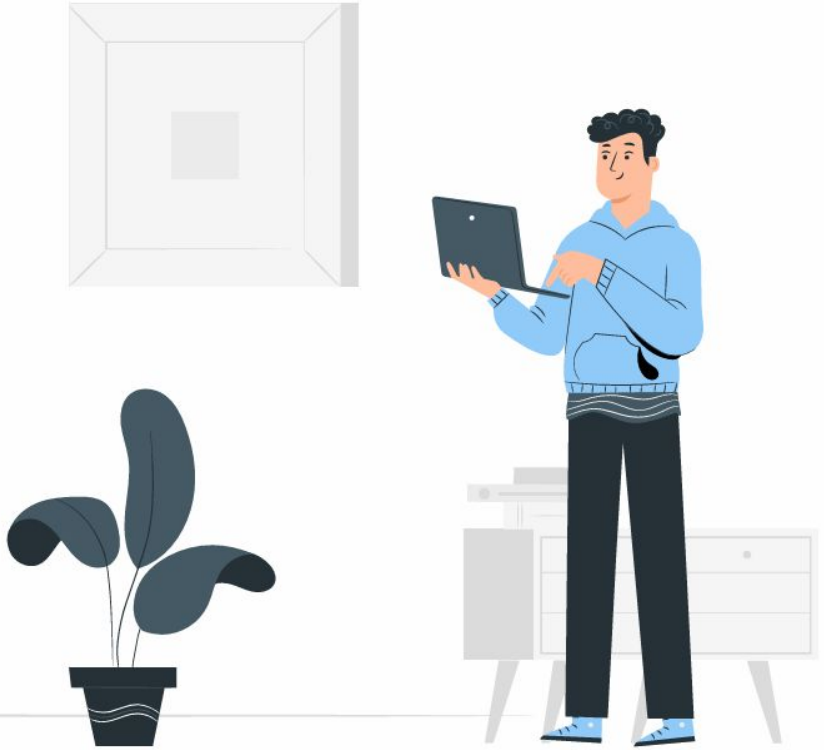
- Создание единого хранилища данных для всех подразделений компании
- Повышение качества принимаемых управленческих решений
- Оптимизация маркетинговых затрат
- Повышение точности прогнозов спроса
- Улучшение качества обслуживания клиентов
- Увеличение прибыльности компании
- Ускорение отчетности

Функциональные требования:

- Интеграция данных из всех источников (CRM, ERP, POS-терминалы, складские системы)
- Хранение исторических данных
- Поддержка OLAP-аналитики
- Автоматизация ETL-процессов
- Обеспечение безопасности данных с разграничением прав доступа

02

Придумать как минимум три системы источника, в каждой из которых данные передаются в своем формате



Системы источников данных для DWH

- Торговая система POS. Формат данных: XML с элементами JSON
- Система управления складом. Формат данных: CSV с разделителем
- CRM-система. Формат данных: JSON с вложенными объектами
- Система маркетинга. Формат: XML
- Онлайн-магазин (API)



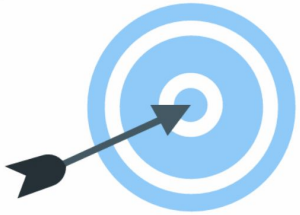
03

Разработать модель данных для DWH, включая измерения, факты и связи между ними


Customers
ID клиента
ФИО
Телефон
Email
Регион
ID программы лояльности
Sales
ID транзакции
ID клиента
ID магазина
ID сотрудника
Сумма
Скидка
Тип оплаты
Sales-Products
ID транзакции
ID товара
Количество
Сумма
Products
ID товара
Наименование
Единица измерения
Категория
Подкатегория
Производитель
Цена закупки
Цена продажи
Loyalty
ID программы лояльности
Название
Скидка
Stores
ID магазина
Название
Регион
Адрес
Площадь
Employees
ID сотрудника
ID магазина
ФИО
Телефон
Email
Регион
ID Должности
Position
ID должности
Зарплата

Факты

1. Sales
   - PRIMARY KEY(ID транзакции)
   - FOREIGN KEY(ID клиента(Customers), ID магазина(Stores), ID сотрудника(Employees))
2. Sales-Products
   - PRIMARY KEY(ID транзакции, ID товара)
   - FOREIGN KEY(ID транзакции(Sales), ID товара(Products))



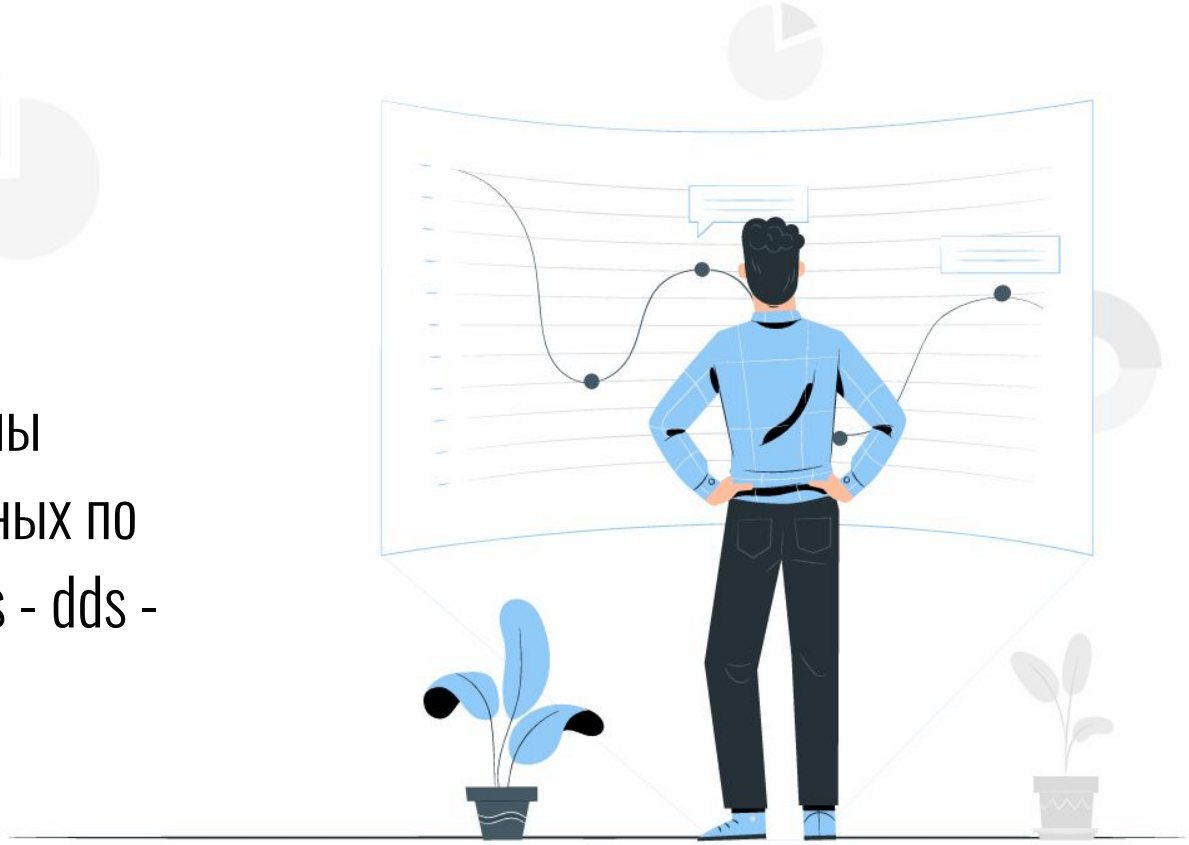


Измерения

1. Customers
   - PRIMARY KEY(ID клиента)
   - FOREIGN KEY(ID программы лояльности(Loyalty))
2. Loyalty
   - PRIMARY KEY(ID программы лояльности)
3. Stores
   - PRIMARY KEY(ID магазина)
4. Employees
   - PRIMARY KEY(ID сотрудника)
   - FOREIGN KEY(ID магазина(Stores), ID Должности(Position))
5. Position
   - PRIMARY KEY(ID должности)
6. Products
   - PRIMARY KEY(ID товара)

04

Описать принципы разложения данных по слоям stage - ods - dds - datamart





Слой Stage

- Цель: Временное хранилище "сырых" данных из источников без изменений
- Данные загружаются в том виде, в котором поступили из источников (CRM, ERP, POS-терминалы, складские системы и т.д.)
- Форматы сохраняются максимально приближенными к исходным (XML, JSON, CSV).
- Минимальная обработка: только контроль целостности файлов, преобразование в таблицы для удобства загрузки

Слой ODS

- Цель: Операционное хранилище очищенных и унифицированных данных
- Преобразование данных к реляционной структуре
- Очистка: удаление дубликатов, базовая валидация, нормализация форматов (например, даты, номера телефонов)
- Сведение данных из разных источников по ключам (например, сопоставление клиентов из CRM и POS)
- Сохраняется история изменений (SCD2), если требуется

Слой DDS

- Цель: Нормализованное хранилище бизнес-данных, подготовленное для построения витрин (datamart)
- Полная нормализация: разносится по сущностям (факт и измерения)
- Четкая структура связей (PK, FK)
- Данные агрегируются, очищаются, обогащаются справочниками
- Поддержка истории изменений (SCD2/SCD3) по необходимости
- Служит основой для построения витрин и аналитических отчетов

Слой Datamart

- Цель: Оптимизированные под задачи аналитики структуры (звезда, снежинка)
- Данные агрегируются и денормализуются для быстрого доступа
- Формируются витрины под конкретные задачи: продажи по регионам, эффективность сотрудников, анализ лояльности и т.д
- Используются для построения отчетности, BI, ML



Автор:

Багаева Алина

Группа OTUS DWH-2025-04